

占用率预测模型系统化调参记录

本文档记录 OccuEVRoute 充电站占用率预测模型的系统化调参过程。阅读对象是项目组成员，重点是说明：我们为什么调参、如何避免数据泄漏、尝试了哪些搜索方法、最终为什么采用 Optuna 参数，以及当前部署模型对应的指标。

1. 最终结论

当前最终模型采用 Optuna 找到的 XGBoost 参数，并已经重新训练和覆盖模型制品：

```
models/occupancy_horizon_xgboost.pkl
```

最终模型指标为：

```
overall MAE = 0.023527
overall R2  = 0.950467
```

最终采用的参数为：

```
n_estimators = 800
max_depth = 10
learning_rate = 0.013387836038795686
subsample = 0.60
colsample_bytree = 0.80
min_child_weight = 7
reg_alpha = 0.01
reg_lambda = 15.0
```

这组参数来自 Optuna 第 53 个 trial。它比基础经验参数和前一轮随机搜索参数都更好。

2. 调参目标

当前模型是一个多 horizon **XGBRegressor**，预测未来某个时间点的充电站占用率：

```
target_occupancy_rate = occupancy_rate(t + prediction_horizon_min)
```

调参前，模型使用手工经验参数：

```
n_estimators = 500
max_depth = 5
learning_rate = 0.04
```

```
subsample = 0.85  
colsample_bytree = 0.85
```

本次调参的目标是：在不改变特征工程的前提下，用 validation MAE 系统选择 XGBoost 参数，并确认新参数在独立 test 集上也能提升。

主指标：

```
validation MAE
```

辅助指标：

```
validation R2  
test MAE  
test R2  
by-horizon MAE  
by-horizon R2
```

3. 模型与特征范围

本次只调 XGBoost 超参数，不改变输入特征。

使用的特征集：

```
horizon_context_lag_no_station_id
```

该特征集包含 52 个特征，覆盖预测 horizon、当前/目标时刻时间特征、天气、站点静态属性、价格、POI、站点历史画像、邻近站点画像、占用率滞后与滚动统计。

本次没有加入 `station_id` 作为特征，避免模型主要记忆站点编号。

4. 数据切分与防泄漏

占用率预测具有时间序列属性，因此本次调参使用按时间顺序的三段式切分：

```
train:      time < 2023-01-01T00:00:00  
validation: 2023-01-01T00:00:00 <= time < 2023-01-23T19:05:00  
test:       time >= 2023-01-23T19:05:00
```

实际样本量：

```
train rows:      485605  
validation rows: 90631
```

```
test rows:      143764
```

防泄漏规则：

- 参数选择只看 validation 指标。
- test 数据只用于最终比较，不参与参数搜索。
- 滞后特征和滚动特征只使用当前时刻之前的数据。
- 站点历史画像、同小时画像和邻居画像只在训练段拟合，再应用到 validation 或 test。
- 目标值只来自 `time + prediction_horizon_min`。

5. 第一轮：两阶段随机搜索

第一轮使用自定义随机搜索脚本：

```
src/waiting_prediction/tune_horizon_xgboost.py
```

运行命令：

```
python src/waiting_prediction/tune_horizon_xgboost.py --max-stations 0 --base-rows-per-station 1000 --max-rows-per-horizon 80000 --stage1-trials 80 --stage2-trials 40
```

搜索方式：

```
stage1 = 80 组宽范围随机搜索
stage2 = 40 组围绕 stage1 前 5 名的局部搜索
```

随机搜索最佳参数来自 `stage2 trial 23`：

```
n_estimators = 500
max_depth = 9
learning_rate = 0.02
subsample = 0.85
colsample_bytree = 0.90
min_child_weight = 7
reg_alpha = 0.05
reg_lambda = 15.0
```

随机搜索结果：

模型	validation MAE	validation R2	test MAE	test R2
基础参数	0.030214	0.928110	0.024764	0.949001

模型	validation MAE	validation R2	test MAE	test R2
随机搜索最佳参数	0.028780	0.930691	0.023630	0.950328

随机搜索证明：系统化搜索可以明显优于基础经验参数。

输出文件：

```
docs/figures/occupancy_horizon_tuning_results.csv
docs/figures/occupancy_horizon_tuning_by_horizon.csv
docs/figures/occupancy_horizon_tuning_comparison.csv
models/occupancy_horizon_best_params.json
```

6. 第二轮：Optuna 搜索

第二轮使用 Optuna 做智能超参数搜索。Optuna 使用 TPE sampler，根据已经完成的 trial 自动选择后续更有潜力的参数组合。

脚本：

```
src/waiting_prediction/tune_horizon_xgboost_optuna.py
```

运行命令：

```
python src/waiting_prediction/tune_horizon_xgboost_optuna.py --max-stations 0 --
base-rows-per-station 1000 --max-rows-per-horizon 80000 --trials 60
```

Optuna 设置：

```
trials = 60
sampler = TPESampler
selection_metric = validation_mae
random_seed = 42
```

Optuna 最佳参数来自 **trial 53**：

```
n_estimators = 800
max_depth = 10
learning_rate = 0.013387836038795686
subsample = 0.60
colsample_bytree = 0.80
min_child_weight = 7
```

```
reg_alpha = 0.01
reg_lambda = 15.0
```

Optuna 结果：

模型	validation MAE	validation R2	test MAE	test R2
基础参数	0.030214	0.928110	0.024764	0.949001
Optuna 最佳参数	0.028643	0.931132	0.023547	0.950557

Optuna 比随机搜索的 test MAE **0.023630** 进一步降低到 **0.023547**，因此最终选择 Optuna 参数。

输出文件：

```
docs/figures/occupancy_horizon_optuna_trials.csv
docs/figures/occupancy_horizon_optuna_by_horizon.csv
docs/figures/occupancy_horizon_optuna_comparison.csv
models/occupancy_horizon_optuna_best_params.json
```

7. 最终训练

Optuna 参数确定后，使用 train + validation 的完整训练段重新训练最终模型，并继续用 test 段评估。

最终训练命令：

```
python src/waiting_prediction/train_lagged_occupancy_model.py --max-stations 0 --
base-rows-per-station 1000 --max-rows-per-horizon 80000 --shap-sample-size 3000 --
model-params-file models/occupancy_horizon_optuna_best_params.json
```

最终训练输出：

```
models/occupancy_horizon_xgboost.pkl
models/occupancy_horizon_features.json
docs/figures/occupancy_horizon_model_metrics.csv
docs/figures/occupancy_horizon_by_horizon_metrics.csv
docs/figures/occupancy_horizon_feature_set_metrics.csv
docs/figures/occupancy_horizon_feature_importance.csv
docs/figures/occupancy_horizon_shap_importance.csv
docs/figures/occupancy_horizon_shap_bar.png
docs/figures/occupancy_horizon_shap_summary.png
```

最终主模型指标：

指标	数值
MAE	0.023527
R2	0.950467

8. 最终模型分 horizon 结果

Horizon 分钟	MAE	Relative MAE	R2
5	0.012073	4.94%	0.979950
10	0.013963	5.69%	0.974227
15	0.015088	6.16%	0.972052
20	0.017075	7.00%	0.965989
30	0.020175	8.25%	0.961891
45	0.023694	9.79%	0.955410
60	0.028964	11.90%	0.939334
90	0.037669	15.32%	0.911971
120	0.042834	17.62%	0.894316

短期 horizon 的相对 MAE 低于 10%；120 分钟预测的相对 MAE 为 17.62%，R2 为 0.894316。

9. 对组内汇报的解释

可以这样概括本次调参：

初始 XGBoost 模型使用经验参数。我们先用时间验证集做两阶段随机搜索，证明系统化调参能降低 test MAE；随后使用 Optuna 的 TPE sampler 做 60 次智能搜索，进一步找到更优参数。最终模型采用 Optuna 参数重新训练，在独立 test 集上 MAE 降到 0.023527，R2 达到 0.950467。

关键点：

- 没有使用随机 K 折，避免时间序列泄漏。
- test 集没有参与参数选择，只用于最终验证。
- 最终模型已经重新训练并覆盖 `models/occupancy_horizon_xgboost.pkl`。
- 当前后端加载模型时，会使用 Optuna 调参后的模型制品。